

Relatorio Analitico dos Experimentos RNG + Random Forest

Classificacao morfologica de galaxias sob variacao de seeds, geradores pseudoaleatorios, random_state interno, tamanho de dataset e tempo de split

Base analisada: cinco experimentos executados no repositorio galaxy-rng-experiment, com resultados resumidos em CSV e artefatos brutos mantidos localmente. Documento preparado para apoiar interpretacao dos resultados e selecao de achados para artigo curto.

1. Sumario executivo

A bateria confirma que a classificacao morfologica por Random Forest e relativamente robusta em acuracia, mas apresenta variabilidade mensuravel quando mudamos a composicao dos conjuntos de treino, validacao e teste. O F1 macro, por ser mais sensivel ao desempenho por classe, revela melhor as oscilacoes causadas por seeds, geradores e tamanho de amostra.

O Experimento 1 mostra que, com Random Forest fixo em random_state 42, as diferencas medias entre geradores sao pequenas, mas a dispersao entre seeds existe e deve ser reportada. O Experimento 2 isola a aleatoriedade interna do modelo e mostra variacao menor que nos cenarios em que o split tambem muda. O Experimento 3 combina ambas as fontes. O Experimento 4 mostra que amostras menores amplificam instabilidade. O Experimento 5 evidencia custo de tempo maior no gerador PCG64-CP A Lite 1 para a etapa de split.

Mensagem central: avaliar apenas uma seed pode ocultar a incerteza experimental. Neste pipeline, a escolha da seed e do split importa mais para a variabilidade do que a mudanca isolada do random_state interno do Random Forest.

Experimentos executados

Experimento	Fator variado	Execucoes
1	Gerador e seed do split; RF fixo em 42	90
2	random_state interno do RF; split fixo	30
3	Seed do split e random_state acoplados	90
4	Tamanho do dataset, gerador e seed	360
5	Tempo de geracao do split	90

2. Metodologia e leitura dos resultados

Todos os experimentos utilizam o dataset preparado de galaxias com 34.874 amostras na condicao completa, divisao estratificada em treino, validacao e teste e RandomForestClassifier como classificador. As metricas principais analisadas sao acuracia de teste e F1 macro de teste; a acuracia mede desempenho global, enquanto o F1 macro pesa igualmente as classes e tende a expor melhor desequilibrios por classe.

A politica de versionamento separa resultados brutos e resumos. Os arquivos JSON completos e datasets derivados permanecem locais; os CSVs resumidos e metadados sao os artefatos versionados e analisados neste relatorio. No Experimento 4, o resumo automatico por gerador agrega diferentes tamanhos de dataset; por isso, este relatorio tambem calcula estatisticas por tamanho de dataset.

Tabela comparativa dos experimentos

Exp.	n	Fator central	Acc. media	Acc. dp	F1 medio	F1 dp
1	90	Split por gerador/seed	93.65%	0.315 pp	87.91%	0.626 pp
2	30	RF random_state	93.36%	0.129 pp	87.34%	0.253 pp
3	90	Split + RF acoplados	93.64%	0.293 pp	87.90%	0.586 pp
4	360	Tamanho do dataset	93.32%	0.436 pp	87.31%	0.832 pp
5	90	Tempo de split	-	-	-	-

3. Experimento 1 - influencia do split


Neste experimento variam o gerador pseudoaleatorio e a seed usados para formar treino, validacao e teste. O random_state interno do Random Forest fica fixo em 42. Assim, a pergunta isolada e: quanto a composicao dos conjuntos de dados altera as metricas finais?

Tabela 1 - desempenho por gerador

Grupo	n	Acc. media	Acc. dp	F1 medio	F1 dp
MT19937	30	93.65%	0.312 pp	87.90%	0.649 pp
NumPy PCG64	30	93.75%	0.316 pp	88.14%	0.616 pp
PCG64-CP A Lite 1	30	93.54%	0.316 pp	87.70%	0.612 pp


Interpretacao: o achado principal nao e que um gerador vence de forma absoluta, mas que a seed do split cria uma faixa de resultados. Portanto, resultados reportados com uma unica seed devem ser tratados como estimativas pontuais fragilizadas.

Figura 1 - distribuicao por gerador



Boxplots de acuracia e F1 macro mostram que as medias entre geradores sao muito proximas, mas ha variacao nao desprezivel entre seeds. O F1 macro apresenta dispersao visualmente mais informativa que a acuracia.

Figura 2 - trajetoria por seed



As linhas por seed mostram que parte da oscilacao ocorre de forma local, isto e, algumas seeds produzem splits mais favoraveis ou desfavoraveis independentemente do gerador.


4. Experimento 2 - aleatoriedade interna do Random Forest

Aqui o split permanece fixo com numpy_pcg64 e seed 123456789, enquanto o random_state interno do Random Forest varia de 1000 a 1029. O desenho isola a pergunta: mantendo exatamente as mesmas galaxias em treino, validacao e teste, quanto a construcao aleatoria das arvores altera o resultado?

Tabela 2 - variabilidade com split fixo

Grupo	n	Acc. media	Acc. dp	F1 medio	F1 dp
NumPy PCG64	30	93.36%	0.129 pp	87.34%	0.253 pp

Figura 3 - metricas por random_state do modelo



A oscilacao existe, mas e pequena: o desvio padrao da acuracia de teste foi de aproximadamente 0.129 pp, e o do F1 macro foi de aproximadamente 0.253 pp.

Interpretacao: a aleatoriedade interna do Random Forest influencia o resultado, mas neste conjunto ela parece menos dominante do que a variacao do split. Isso sustenta uma estrategia experimental em duas camadas: primeiro controlar e repetir splits, depois quantificar o modelo.

5. Experimento 3 - seed do split e random_state acoplados


Neste desenho, a mesma seed controla o split e o random_state do Random Forest. O objetivo e observar a variabilidade total quando as duas fontes de aleatoriedade mudam juntas. Esse cenario e util como limite pratico, mas deve ser interpretado com cautela porque mistura dois efeitos.

Tabela 3 - desempenho com fontes acopladas

Grupo	n	Acc. media	Acc. dp	F1 medio	F1 dp
MT19937	30	93.64%	0.275 pp	87.90%	0.567 pp
NumPy PCG64	30	93.73%	0.294 pp	88.08%	0.582 pp
PCG64-CP A Lite 1	30	93.55%	0.311 pp	87.72%	0.610 pp


Interpretacao: este experimento reforca que a variabilidade total deve ser reportada, mas nao substitui os experimentos isolados. Para explicar causalmente o efeito, o Experimento 1 e o Experimento 2 sao mais limpos; o Experimento 3 funciona como simulacao de uso pratico.

Figura 4 - distribuicao com seed acoplada



Os boxplots preservam o padrao de medias muito proximas entre geradores, com diferencas mais visiveis na dispersao do F1 macro.

Figura 5 - comparacao de dispersao entre Experimentos 1 e 3



A comparacao de desvios mostra se acoplar o random_state do modelo a seed do split aumenta ou reduz a instabilidade em relacao ao split isolado. O resultado sugere que a variabilidade permanece na mesma ordem de grandeza.

6. Experimento 4 - tamanho do dataset


Este experimento repete o protocolo com 25%, 50%, 75% e 100% do dataset preparado, mantendo Random Forest fixo em 42. A pergunta e se a sensibilidade a seed e gerador diminui conforme aumentamos a quantidade de dados.

Tabela 4 - desempenho agregado por tamanho de dataset

Dataset	n	Acc. media	Acc. dp	F1 medio	F1 dp
8718	90	92.88%	0.646 pp	86.56%	1.194 pp
17437	90	93.28%	0.429 pp	87.21%	0.827 pp
26156	90	93.46%	0.343 pp	87.56%	0.662 pp
34874	90	93.65%	0.323 pp	87.91%	0.645 pp


Interpretacao: este e um dos experimentos mais fortes para o artigo, pois conecta tamanho amostral e estabilidade. A conclusao recomendada e que a incerteza por seed deve ser ainda mais enfatizada quando a classificacao usa subconjuntos reduzidos do catalogo.

Figura 6 - desempenho por tamanho e gerador



As barras de erro mostram a media e o desvio por tamanho de dataset. O aumento da amostra tende a estabilizar as metricas e reduzir a sensibilidade a combinacoes especificas de seed.

Figura 7 - variabilidade por tamanho de dataset



A variabilidade cai ou se estabiliza conforme o dataset cresce. Esta figura e central para discutir robustez experimental e necessidade de multiplas seeds, sobretudo em amostras menores.


7. Experimento 5 - tempo de geracao dos splits

O ultimo experimento mede apenas o tempo para gerar splits estratificados por gerador e seed, sem treinar o modelo. Essa medida permite separar qualidade preditiva de custo computacional da etapa de aleatoriedade.

Tabela 5 - tempo medio por gerador

Gerador	n	Media	dp	Min.	Max.
NumPy PCG64	30	0.0053 s	0.0003 s	0.0052 s	0.0066 s
MT19937	30	0.0054 s	0.0001 s	0.0053 s	0.0058 s
PCG64-CP A Lite 1	30	0.2970 s	0.0020 s	0.2936 s	0.3004 s

Figura 8 - comparacao de tempo de split



O gerador PCG64-CP A Lite 1 apresentou tempo medio muito maior para geracao do split. Esse achado nao invalida o gerador, mas deve ser discutido como custo computacional da abordagem.

Interpretacao: o gerador mais rapido foi NumPy PCG64 com media de 0.0053 s por split. O mais lento foi PCG64-CP A Lite 1 com media de 0.2970 s por split, cerca de 56.5 vezes mais lento nesta etapa.

8. Analise estatistica comparativa

A comparacao entre experimentos indica que as medias de acuracia e F1 macro permanecem altas em todos os cenarios, mas a dispersao muda conforme a fonte de aleatoriedade analisada. O Experimento 2, que varia apenas o Random Forest com split fixo, possui dispersao menor; os Experimentos 1 e 3, que alteram a composicao dos conjuntos, exibem variabilidade mais relevante. O Experimento 4 mostra que a variabilidade tambem e modulada pelo tamanho do dataset.

A diferenca media entre geradores e pequena o suficiente para evitar uma afirmacao forte de superioridade universal. O resultado cientificamente mais defensavel e sobre estabilidade: multiplas seeds sao necessarias para caracterizar a faixa de desempenho, principalmente quando se reporta F1 macro.

Em termos de prioridade estatistica, o F1 macro deve receber destaque no artigo porque responde melhor a possiveis desequilibrios entre classes morfologicas. A acuracia continua importante, mas pode mascarar variacoes por classe.

9. Achados recomendados para o artigo

Achado 1. A seed do split influencia a classificacao de forma mensuravel; portanto, avaliar uma unica seed e metodologicamente fraco.

Achado 2. A variacao isolada do random_state interno do Random Forest produz oscilacao menor do que a mudanca do split, sugerindo que a composicao treino/teste e a fonte mais importante neste pipeline.

Achado 3. As medias entre geradores sao proximas; o foco do artigo deve ser estabilidade, dispersao e reprodutibilidade, nao uma narrativa simples de vencedor absoluto.

Achado 4. Tamanhos menores de dataset aumentam a relevancia da variabilidade por seed, tornando o Experimento 4 uma evidencia forte para discutir robustez amostral.

Achado 5. O PCG64-CP A Lite 1 tem custo de tempo maior na etapa de split; esse resultado deve ser apresentado como trade-off computacional, separado da qualidade preditiva.

Sugestao de titulo para o artigo: **Sensibilidade de classificadores morfologicos de galaxias a seeds e geradores pseudoaleatorios**. Uma formulacao alternativa, mais metodologica, seria: **Reprodutibilidade experimental em classificacao morfologica de galaxias: avaliacao de seeds, PRNGs e Random Forest**.

10. Limitacoes e proximos passos

Os resultados sao fortes para uma analise inicial, mas ainda dependem de um classificador principal e de um dataset preparado especifico. Para uma versao futura, recomenda-se incluir testes estatisticos formais entre distribuicoes, intervalos de confianca por bootstrap, analise por classe usando matrizes de confusao agregadas e repeticao com outro classificador. Tambem e recomendavel gerar uma tabela especifica por tamanho e gerador para o Experimento 4 como material suplementar.

Apendice - arquivos analisados

Exp. 1: results/experiment_summaries/01_split_seed/random_forest_runs.csv

Exp. 2: results/experiment_summaries/02_model_state/random_forest_runs.csv

Exp. 3: results/experiment_summaries/03_coupled_seed/random_forest_runs.csv

Exp. 4: results/experiment_summaries/04_dataset_size/random_forest_runs.csv

Exp. 5: results/experiment_summaries/05_split_timing/split_timing_runs.csv

Artefatos gerados pelo relatorio: figuras em output/pdf/figures/ e tabelas compactas em output/pdf/tables/.